

Documentação do Sistema – Agente EDA AI

Objetivo da Aplicação

A aplicação analisa dados de um dataset. O fluxo é organizado em três agentes (Aquisição, Análise e Conclusão Geral), gerando HTML com gráficos e tabelas.

Agentes do Sistema

Agente 1 – Aquisição de Documentos

Gerencia a interface Streamlit; recebe o CSV; preserva estado na sessão; orquestra chamadas ao Agente 2.

Prompt/Comportamento:

- Upload de CSV
- Perguntas categorizadas (Distribuição, Padrões, Anomalias, Relações)
- Encaminha solicitações ao Agente 2 e acumula conclusões

Agente 2 – Análise de Dados

Gera contexto via SQL (SQLite), responde em português e produz HTML com gráficos, tabelas e conclusões.

Prompt do Agente 2 (resumo)

Aja como um analista de dados e responda a seguinte PERGUNTA {pergunta}

...

(Conteúdo integral do prompt presente no código fonte; ver documentação principal)

Agente 3 – Conclusão Geral

Consolida as conclusões anteriores e gera um HTML final com visualizações e destaques.

Prompt do Agente 3 (resumo)

Aja como um analista de dados que analisou dados relativos a um dataset...

(Conteúdo integral do prompt presente no código fonte; ver documentação principal)

Outros Métodos e Objetivos

llm_gera_query(...): Gera SQL compatível com SQLite, coleta colunas via PRAGMA, ajusta LIMIT com base em tokens.

rag(...): Carrega o CSV em SQLite e invoca llm_gera_query para obter a query final.

num_tokens_from_string(...): Conta tokens para regular o volume do contexto.

ErroProcessamento: Exceção para falhas ou excesso de tentativas.

Instalação e Configuração

Faça o download do código, do arquivo requirements.txt e do script plotly.js

[Script agente_eda.py](#)

[Arquivo requirements.txt](#)

[plotly.js](#) (Deve ser colocado dentro da pasta “Scripts”)

Crie um ambiente virtual e ative:

```
python -m venv venv
source venv/bin/activate    # Linux/Mac
venv\Scripts\activate      # Windows
```

Instale as dependências:

```
pip install -r requirements.txt
```

Crie o arquivo .env, dentro da pasta “Scripts”, com sua chave de API gerada no provedor [Openrouter](#)

```
API_KEY="sua_chave_aqui"
```

Rode a aplicação:

```
streamlit run agente_fraudecredito.py
```

Versão de Testes

<https://agente-eda-ai.streamlit.app/>

Como Manipular a Interface Gráfica

- Upload do [CSV](#)
- Exploração: Distribuição / Padrões / Anomalias / Relações
- Clique em “Consultar” para cada seção
- Finalize com “Conclusão Geral” (limpa histórico)

Perguntas Cadastradas

Distribuição

- Quais são os tipos de dados (numéricos, categóricos)?
- Qual a distribuição de cada variável ? (histogramas, distribuições)
- Qual o intervalo de cada variável (mínimo, máximo)?
- Quais são as medidas de tendência central (média, mediana)?
- Qual a variabilidade dos dados (desvio padrão, variância)?

Padrões

- Existem padrões ou tendências temporais?
- Quais os valores mais frequentes ou menos frequentes?
- Existem agrupamentos (clusters) nos dados?

Anomalias

- Existem valores atípicos nos dados?
- Como esses outliers afetam a análise?
- Podem ser removidos, transformados ou investigados?

Relações

- Como as variáveis estão relacionadas umas com as outras? (Gráficos de dispersão, tabelas cruzadas)
- Existe correlação entre as variáveis?
- Quais variáveis parecem ter maior ou menor influência sobre outras?

Tecnologias e Frameworks Utilizados


Tecnologia	Versão
pandas	2.3.0

pydantic	2.11.7
python-dotenv	1.1.0
sqlalchemy	2.0.41
packaging	25.0
protobuf	5.29.5
langchain	0.3.25
langchain-community	0.3.25
langchain-core	0.3.74
streamlit	1.46.0
cachetools	5.5.2
matplotlib	3.10.3
langchain-openai	0.3.31
openpyxl	3.1.5
transformers	4.57.0
transformers.utils	0.0.1
torch	2.8.0

Mecanismo de Memória

Uso de `st.session_state` (histórico de perguntas/conclusões) e `InMemoryCache` para cache de LLM.

Imagens Execuções



Agente Análise Fraude Cartão AI

Ex: Arquivo csv de dados

Carregue o arquivo csv de dados

Drag and drop file here
Limit 200MB per file • CSV

Browse files

creditcard.csv 143.8MB

Descrição dos dados. Escolha uma opção

Qual o intervalo de cada variável (mínimo, máximo)?

Consultar

Intervalo das Variáveis (Mínimo e Máximo)

Dados Utilizados:

30 transações do arquivo de fraudes (amostra fornecida no contexto).

Tabela de Intervalos:


Variável	Mínimo	Máximo
Time	0.0	23.0
V1	-5.401258	1.492936
V2	-5.450148	1.449044
V3	-1.361819	2.536347
V4	-1.582122	2.712520
V5	-1.971383	3.721818



V18 -	
V17 -	
V16 -	
V15 -	
V14 -	
V13 -	
V12 -	
V11 -	
V10 -	
V9 -	
V8 -	
V7 -	

Conclusão Geral

Correlações entre Variáveis (V1-V28)



Destaque para correlação V2-V5 (0.61) e V7-V10 (-0.58)

Evidências de Teste

Pergunta 1

Quais são os tipos de dados (numéricos, categóricos)?

Resposta

Análise de Dados - Fraudes em Cartão de Crédito

Tipos de Dados por Coluna

- **Numéricas:** Time, V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V13, V14, V15, V16, V17, V18, V19, V20, V21, V22, V23, V24, V25, V26, V27, V28, Amount
- **Categóricas:** Class

Tabela de Dados com Formatação Condicional (Amount)


Time	V1	V2	V3	V4	V5	V6	V7	V8	V9
0.0	-1.359807	-0.072781	2.536347	1.378155	-0.338321	0.462388	0.239599	0.098698	0.363787
0.0	1.191857	0.266151	0.166480	0.448154	0.060018	-0.082361	-0.078803	0.085102	-0.255425
1.0	-1.358354	-1.340163	1.773209	0.379780	-0.503198	1.800499	0.791461	0.247676	-1.514654
1.0	-0.966272	-0.185226	1.792993	-0.863291	-0.010309	1.247203	0.237609	0.377436	-1.387024
2.0	-1.158233	0.877737	1.548718	0.403034	-0.407193	0.095921	0.592941	-0.270533	0.817739


V10	V11	V12	V13	V14	V15	V16	V17	V18
0.090794	-0.551600	-0.617801	-0.991390	-0.311169	1.468177	-0.470401	0.207971	0.025791
-0.166974	1.612727	1.065235	0.489095	-0.143772	0.635558	0.463917	-0.114805	-0.183361
0.207643	0.624501	0.066084	0.717293	-0.165946	2.345865	-2.890083	1.109969	-0.121359
-0.054952	-0.226487	0.178228	0.507757	-0.287924	-0.631418	-1.059647	-0.684093	1.965775

V10	V11	V12	V13	V14	V15	V16	V17	V18
0.753074	-0.822843	0.538196	1.345852	-1.119670	0.175121	-0.451449	-0.237033	-0.038195

V19	V20	V21	V22	V23	V24	V25	V26	V27	V28	Amount	Class
0.403993	0.251412	-0.018307	0.277838	-0.110474	0.066928	0.128539	-0.189115	0.133558	-0.021053	149.62	0
-0.145783	-0.069083	-0.225775	-0.638672	0.101288	-0.339846	0.167170	0.125895	-0.008983	0.014724	2.69	0
-2.261857	0.524980	0.247998	0.771679	0.909412	-0.689281	-0.327642	-0.139097	-0.055353	-0.059752	378.66	0
-1.232622	-0.208038	-0.108300	0.005274	-0.190321	-1.175575	0.647376	-0.221929	0.062723	0.061458	123.50	0
0.803487	0.408542	-0.009431	0.798278	-0.137458	0.141267	-0.206010	0.502292	0.219422	0.215153	69.99	0

Distribuição do Valor das Transações (Amount)





Conclusões

Tipos de dados identificados:

- **Numéricas contínuas:** Time, V1 a V28 (resultantes de PCA), Amount.
- **Catégorica binária:** Class (0, 1).

Dados utilizados: 5 primeiras linhas do dataset fornecidas no contexto.

Pergunta 2

Quais os valores mais frequentes ou menos frequentes?

Resposta

Análise de Valores Mais/Menos Frequentes

Resumo Estatístico (Amostra)

Coluna	Valor Mais Frequente	Valor Menos Frequente
Class	0 (Normal)	1 (Fraude)

Amount	Valores Baixos (ex: 0.89, 2.69)	Valores Altos (ex: 378.66, 231.71)
--------	------------------------------------	---------------------------------------

Conclusões

- **Class:** A classe 0 (normal) é dominante na amostra.
- **Amount:** Transações de baixo valor são mais comuns.

Pergunta 3

Existem valores atípicos nos dados?

Resposta

Análise de Valores Atípicos

Colunas com Valores Atípicos

Coluna	Outliers Identificados
Time	23 (máximo)
V3	2.536, 1.773
Amount	378.66, 231.71

Conclusões

Resposta à pergunta: Sim, existem valores atípicos nos dados.

Colunas afetadas: Time, V3, V4, V7, V10, V11, V12, V14, V16, V17, Amount.

Dados utilizados: Amostra de 28 transações fornecidas no contexto.

Pergunta 4

Podem ser removidos, transformados ou investigados?

Resposta

Análise de Dados - Fraudes em Cartão de Crédito

Dados Utilizados (Amostra de 28 Transações)

Time	V1	V2	V3	V4	V5	V6	V7	V8	V9	V10	V11	V12	V13
0.0	-1.36	-0.07	2.54	1.38	-0.34	0.46	0.24	0.10	0.36	0.09	-0.55	-0.62	-0.99

V14	V15	V16	V17	V18	V19	V20	V21	V22	V23	V24	V25	V26
-0.31	1.47	-0.47	0.21	0.03	0.40	0.25	-0.02	0.28	-0.11	0.07	0.13	-0.19

V27	V28	Amount	Class
0.13	-0.02	149.62	0

Conclusões

Resposta à Pergunta: As colunas que devem ser:

- **Investigadas:** Time, V3, V10, V11, V14, V16, V17, Amount
- **Transformadas:** Amount (normalização/log)
- **Removidas:** Nenhuma

Dados Utilizados: Amostra de 28 transações das colunas Time, V1-V28, Amount e Class.

Pergunta 5

Existe correlação entre as variáveis?

Resposta

Análise de Correlação entre Variáveis

Dados Utilizados

28 transações das colunas: Time, V1-V28, Amount, Class

Conclusões

- **Correlações significativas ($> |0.4|$):**
 - V2 e V5: +0.63
 - V7 e V10: -0.58
 - Amount e V25: +0.50
 - V18 e V9: -0.52
- **Class (fraude) tem correlação moderada com:**
 - V14: -0.31
 - V10: +0.29
- Time e Amount mostram baixa correlação com outras variáveis

Resposta à pergunta: Existem correlações significativas principalmente entre variáveis V (ex: V2-V5, V7-V10) e entre Amount-V25. Class tem correlação fraca com V14 e V10.

Pergunta 5

Conclusão Geral


Resposta

Análise de Transações com Cartão de Crédito

Distribuição de Transações




Valores de Transações (Amount)



Valores ≤ 50 são frequentes | Valores ≥ 200 são raros

Outliers em Valores (Amount)



Valores atípicos identificados (ex: **378.66**)

Principais Correlações

Variáveis	Correlação	Impacto em Fraude
V14 e Class	-0.31	Relação negativa
V10 e Class	+0.29	Relação positiva

Conclusões Gerais

- Dados **altamente desbalanceados** (fraudes representam minoria)
- Variável **Amount** requer transformação (log/normalização) devido a outliers
- Colunas **V10 e V14** são as mais relevantes para detecção de fraudes

- Nenhuma coluna deve ser removida - todas contribuem para análise

Conclusão

Documento consolidado com objetivos, prompts, métodos, perguntas, instalação, tecnologias e memória, incluindo gráficos/diagramas ilustrativos.