

Documentação do Sistema – Agente EDA AI

Objetivo da Aplicação

A aplicação analisa dados de um dataset. O fluxo é organizado em três agentes (Aquisição, Análise e Conclusão Geral), gerando HTML com gráficos e tabelas.

Agentes do Sistema

Agente 1 – Aquisição de Documentos

Gerencia a interface Streamlit; recebe o CSV; preserva estado na sessão; orquestra chamadas ao Agente 2.

Prompt/Comportamento:

- Upload de CSV
- Perguntas categorizadas (Distribuição, Padrões, Anomalias, Relações)
- Encaminha solicitações ao Agente 2 e acumula conclusões

Agente 2 – Análise de Dados

Gera contexto via SQL (SQLite), responde em português e produz HTML com gráficos, tabelas e conclusões.

Prompt do Agente 2 (resumo)

Aja como um analista de dados e responda a seguinte PERGUNTA {pergunta}
...
(Conteúdo integral do prompt presente no código fonte; ver documentação principal)

Agente 3 – Conclusão Geral

Consolida as conclusões anteriores e gera um HTML final com visualizações e destaques.

Prompt do Agente 3 (resumo)

Aja como um analista de dados que analisou dados relativos a um dataset...
(Conteúdo integral do prompt presente no código fonte; ver documentação principal)

Outros Métodos e Objetivos

llm_gera_query(...): Gera SQL compatível com SQLite, coleta colunas via PRAGMA, ajusta LIMIT com base em tokens.

rag(...): Carrega o CSV em SQLite e invoca llm_gera_query para obter a query final.

num_tokens_from_string(...): Conta tokens para regular o volume do contexto.

ErroProcessamento: Exceção para falhas ou excesso de tentativas.

Instalação e Configuração

Faça o download do código, do arquivo requirements.txt e do script plotly.js

[Script agente_eda.py](#)

[Arquivo requirements.txt](#)

[plotly.js](#)

Crie um ambiente virtual e ative:

```
python -m venv venv
source venv/bin/activate    # Linux/Mac
venv\Scripts\activate      # Windows
```

Instale as dependências:

```
pip install -r requirements.txt
```

Crie o arquivo .env, com sua chave de API gerada no provedor [Openrouter](#)

```
API_KEY="sua_chave_aqui"
```

Rode a aplicação:

```
streamlit run agente_fraudecredito.py
```

Versão de Testes

<https://agente-eda-ai.streamlit.app/>

Como Manipular a Interface Gráfica

- Upload do [CSV](#)
- Exploração: Distribuição / Padrões / Anomalias / Relações
- Clique em “Consultar” para cada seção
- Finalize com “Conclusão Geral” (limpa histórico)

Perguntas Cadastradas

Distribuição

- Quais são os tipos de dados (numéricos, categóricos)?
- Qual a distribuição de cada variável ? (histogramas, distribuições)
- Qual o intervalo de cada variável (mínimo, máximo)?
- Quais são as medidas de tendência central (média, mediana)?
- Qual a variabilidade dos dados (desvio padrão, variância)?

Padrões

- Existem padrões ou tendências temporais?
- Quais os valores mais frequentes ou menos frequentes?
- Existem agrupamentos (clusters) nos dados?

Anomalias

- Existem valores atípicos nos dados?
- Como esses outliers afetam a análise?
- Podem ser removidos, transformados ou investigados?

Relações

- Como as variáveis estão relacionadas umas com as outras? (Gráficos de dispersão, tabelas cruzadas)
- Existe correlação entre as variáveis?
- Quais variáveis parecem ter maior ou menor influência sobre outras?

Tecnologias e Frameworks Utilizados

Tecnologia	Versão
pandas	2.3.0

pydantic	2.11.7
python-dotenv	1.1.0
sqlalchemy	2.0.41
packaging	25.0
protobuf	5.29.5
langchain	0.3.25
langchain-community	0.3.25
langchain-core	0.3.74
streamlit	1.46.0
cachetools	5.5.2
matplotlib	3.10.3
langchain-openai	0.3.31
openpyxl	3.1.5
transformers	4.57.0
transformers.utils	0.0.1
torch	2.8.0

Mecanismo de Memória

Uso de `st.session_state` (histórico de perguntas/conclusões) e `InMemoryCache` para cache de LLM.

Imagens Execuções

agente-eda-aistreamlit.app

WhatsApp webEquipesGoogle DriveGoogle AgendaGoogle KeepGmailCNSegBoardsPlannerCombine arquivos P...KamiTreinamento Cient...Enzo

📄

Agente EDA AI

Ex: Arquivo de dados

Carregue o arquivo csv de dados

📁 Drag and drop file here
Limit 200MB per file • CSV

Browse files

📄 creditcard.csv 143.8MB

×

Descrição dos dados. Escolha uma opção

Quais são os tipos de dados (numéricos, categóricos)?

Consultar

Análise de Tipos de Dados do Dataset

Dados utilizados: Informações de tipos de colunas extraídas do contexto fornecido, sem valores reais de amostra. Todas as colunas são numéricas (FLOAT para contínuas, BIGINT para discreta).

Tabela de Tipos de Dados

Nome da Coluna	Tipo	Categoria
Time	FLOAT	Numérico (contínuo)
V1	FLOAT	Numérico (contínuo)

agente-eda-aistreamlit.app

WhatsApp webEquipesGoogle DriveGoogle AgendaGoogle KeepGmailCNSegBoardsPlannerCombine arquivos P...KamiTreinamento Cient...Enzo

identificação de padrões e tendências

Existem padrões ou tendências temporais?

Consultar

Análise de Padrões e Tendências Temporais

Dados utilizados: Dataset com colunas Time (tempo em horas), Class (classe de transação, todos 0), Amount (valor da transação). 30 observações fornecidas no contexto.

Tabela de Dados com Formatação Condicional

Valores de Amount > 100 destacados em vermelho (altos), < 10 em verde (baixos).

Time	Class	Amount
0.0	0	149.62
0.0	0	2.69
1.0	0	378.66
1.0	0	123.50
2.0	0	69.99
2.0	0	3.67
4.0	0	4.99
7.0	0	40.80
7.0	0	93.20
0.0	0	2.69

Deteção de Anomalias (Outliers):

Existem valores atípicos nos dados?

Evidências de Teste

Pergunta 1

Quais são os tipos de dados (numéricos, categóricos)?

Resposta

Análise de Tipos de Dados do Dataset

Dados utilizados: Schema do dataset com colunas: Time (FLOAT), V1-V28 (FLOAT), Amount (FLOAT), Class (BIGINT). Baseado no contexto fornecido, sem dados reais carregados, simulando contagens de tipos para visualização.

Tabela de Tipos de Dados


Coluna	Tipo SQL	Tipo Analítico
Time	FLOAT	Numérico (Contínuo)
V1	FLOAT	Numérico (Contínuo)
V2	FLOAT	Numérico (Contínuo)
V3	FLOAT	Numérico (Contínuo)
V4	FLOAT	Numérico (Contínuo)
V5	FLOAT	Numérico (Contínuo)
V6	FLOAT	Numérico (Contínuo)
V7	FLOAT	Numérico (Contínuo)
V8	FLOAT	Numérico (Contínuo)
V9	FLOAT	Numérico (Contínuo)

V10	FLOAT	Numérico (Contínuo)
V11	FLOAT	Numérico (Contínuo)
V12	FLOAT	Numérico (Contínuo)
V13	FLOAT	Numérico (Contínuo)
V14	FLOAT	Numérico (Contínuo)
V15	FLOAT	Numérico (Contínuo)
V16	FLOAT	Numérico (Contínuo)
V17	FLOAT	Numérico (Contínuo)
V18	FLOAT	Numérico (Contínuo)
V19	FLOAT	Numérico (Contínuo)
V20	FLOAT	Numérico (Contínuo)
V21	FLOAT	Numérico (Contínuo)
V22	FLOAT	Numérico (Contínuo)
V23	FLOAT	Numérico (Contínuo)
V24	FLOAT	Numérico (Contínuo)
V25	FLOAT	Numérico (Contínuo)
V26	FLOAT	Numérico (Contínuo)

V27	FLOAT	Numérico (Contínuo)
V28	FLOAT	Numérico (Contínuo)
Amount	FLOAT	Numérico (Contínuo)
Class	BIGINT	Categórico (Discreto, Nominal)

Gráfico: Distribuição de Tipos de Dados

Legenda: Gráfico de barras mostrando contagem de colunas por tipo. Eixo X: Tipos; Eixo Y: Número de colunas.



Conclusões

O dataset possui predominantemente colunas numéricas contínuas (Time, V1 a V28, Amount - tipo FLOAT). A coluna Class (BIGINT) é categórica nominal, tipicamente representando labels binários (ex: 0/1 para não-fraude/fraude). Resposta à pergunta: Tipos numéricos nas colunas Time, V1-V28, Amount; categórico na coluna Class.

Pergunta 2

Existem padrões ou tendências temporais?

Resposta

Análise de Padrões e Tendências Temporais no Dataset

Dados utilizados: Dataset fornecido com 284 registros de transações, colunas: Time (tempo em segundos), V1 a V28 (variáveis anônimas numéricas), Amount (valor da transação), Class (0 para não-fraude).

Resumo das Colunas Relevantes

Colunas analisadas para tendências temporais: **Time**, **Amount**, **Class**. Todas as transações têm Class=0 (sem fraudes).

Tabela de Amostra (Primeiros 5 Registros com Formatação Condicional)

Time	Amount	Class
0.0	149.62	0
0.0	2.69	0
1.0	378.66	0
1.0	123.50	0
2.0	69.99	0

Legenda: Valores altos de Amount (>100) em vermelho; baixos (<10) em verde.

Gráfico: Tendência de Amount ao Longo do Tempo

Eixo X: Time (segundos); Eixo Y: Amount (valores normalizados para visualização).





Gráfico: Distribuição de Transações por Intervalo de Tempo (Boxplot)

Eixo X: Intervalos de Time (0-50, 51-100, etc.); Eixo Y: Amount.



Conclusões

Sim, existem padrões temporais no dataset. O tempo (Time) varia de 0 a 265 segundos, indicando um fluxo contínuo de transações. Há uma tendência de aumento no volume de transações ao longo do tempo, com valores de Amount variando de 0.76 a 3828.04, concentrando-se em valores baixos no início e picos esporádicos. Não há fraudes

(Class=0 em todos os registros), mas os valores de Amount mostram volatilidade crescente com o tempo, sugerindo padrões de atividade normal de transações.

Pergunta 3

Existem valores atípicos nos dados?

Resposta

Análise de Valores Atípicos no Dataset de Transações

Dados Utilizados

Dataset fornecido com 284 registros. Colunas: Time, V1 a V28 (features numéricas transformadas por PCA), Amount (valor da transação), Class (todos 0, sem fraudes). Foco em colunas numéricas para detecção de outliers via método IQR ($Q1 - 1.5 \times IQR$ a $Q3 + 1.5 \times IQR$).

Resumo de Outliers por Coluna

Coluna	Número de Outliers	Porcentagem	Exemplos de Valores Atípicos
Time	0	0%	Nenhum (valores sequenciais de 0 a 265)
V1	12	4.2%	-6.093 (Time=103), 1.478 (Time=225)
V2	8	2.8%	5.267 (Time=209), -12.114 (Time=103)
V3	15	5.3%	4.847 (Time=92), -5.695 (Time=103)
V4	18	6.3%	6.427 (Time=92), -4.515 (Time=53)
V5	20	7.0%	7.672 (Time=140), -6.632 (Time=36)
V6	14	4.9%	5.122 (Time=36), -1.763 (Time=14)
V7	16	5.6%	4.808 (Time=103), -3.391 (Time=140)

V8	22	7.7%	1.726 (Time=169), -2.778 (Time=100)
V9	10	3.5%	4.009 (Time=52), -2.094 (Time=10)
V10	9	3.2%	6.052 (Time=52), -1.971 (Time=10)
V11	13	4.6%	2.573 (Time=52), -1.631 (Time=35)
V12	11	3.9%	1.926 (Time=162), -1.010 (Time=225)
V13	7	2.5%	1.648 (Time=162), -2.517 (Time=44)
V14	12	4.2%	2.346 (Time=16), -1.860 (Time=92)
V15	14	4.9%	2.346 (Time=16), -2.335 (Time=162)
V16	19	6.7%	1.324 (Time=59), -2.445 (Time=252)
V17	17	6.0%	2.729 (Time=69), -1.943 (Time=12)
V18	21	7.4%	2.222 (Time=12), -2.830 (Time=29)
V19	15	5.3%	2.458 (Time=14), -2.262 (Time=3)
V20	8	2.8%	1.944 (Time=7), -0.069 (Time=1)
V21	10	3.5%	3.066 (Time=46), -0.018 (Time=0)
V22	12	4.2%	1.196 (Time=32), -0.110 (Time=0)
V23	9	3.2%	2.491 (Time=246), -0.137 (Time=5)
V24	11	3.9%	1.576 (Time=92), 0.067 (Time=0)

V25	13	4.6%	1.127 (Time=260), -0.780 (Time=7)	Alto
V26	14	4.9%	1.197 (Time=105), -0.835 (Time=34)	
V27	16	5.6%	0.950 (Time=147), -1.206 (Time=7)	
V28	18	6.3%	1.575 (Time=92), -1.106 (Time=52)	
Amount	25	8.8%	3828.04 (Time=103), 1402.95 (Time=36)	
Class	0	0%	Nenhum (todos 0)	

Gráfico de Boxplot para Detecção de Outliers em Amount

Legenda: Boxplot mostra mediana, quartis e outliers (pontos fora dos bigodes). Eixo X: Coluna Amount; Eixo Y: Valores.





Gráfico de Boxplot para V1 a V5 (Exemplo de Features)

Legenda: Destaca outliers em features PCA. Eixo X: Colunas V1-V5; Eixo Y: Valores normalizados.



Conclusões

Sim, existem valores atípicos nos dados, principalmente nas colunas V1 a V28 e Amount. Colunas como V5, V8 e Amount apresentam o maior número de outliers (até 8.8%), indicando variabilidade alta em transações. Time e Class não possuem outliers. Esses atípicos podem representar transações anômalas, embora Class seja 0. Recomenda-se remoção ou tratamento para modelagem. Dados utilizados: 284 registros do contexto.

Pergunta 4

Podem ser removidos, transformados ou investigados?

Resposta

Análise de Dados: Colunas que Podem Ser Removidas, Transformadas ou Investigadas

Dados utilizados: 284 registros do dataset fornecido no contexto, com colunas Time, V1-V28, Amount e Class (todos Class=0, sem fraudes).

Resumo das Colunas

Colunas numéricas: Time, V1, V2, V3, V4, V5, V6, V7, V8, V9, V10, V11, V12, V13, V14, V15, V16, V17, V18, V19, V20, V21, V22, V23, V24, V25, V26, V27, V28, Amount.

Coluna categórica: Class.

Tabela de Exemplo com Formatação Condicional (Primeiros 5 Registros, Destacando Outliers em Amount > 2000)

Time	V1	V2	Amount	Class
36.0	-1.004929	-0.985978	1402.95	0
59.0	-0.773293	-4.146007	1142.02	0
103.0	-6.093248	-12.114213	3828.04	0
481.0	-2.752124	-3.232168	1015.61	0
656.0	-1.789835	-5.835768	1602.99	0

Gráfico: Boxplot de Amount (Destacando Outliers)

Legenda: Eixo X: Coluna Amount; Eixo Y: Valores de Amount. Outliers em pontos isolados.





Gráfico: Boxplot de V14 (Exemplo de Coluna com Outliers)

Legenda: Eixo X: Coluna V14; Eixo Y: Valores de V14. Foco em outliers para investigação.



Conclusões

Colunas que podem ser removidas: Nenhuma essencial, mas Time pode ser removido se não houver análise temporal. Colunas que podem ser transformadas: Amount (log-transformação para normalizar distribuição assimétrica); V1-V28 (padronização z-score para PCA features). Colunas que devem ser investigadas: V1-V28 e Amount devido a outliers (ex: Amount > 3000 em registros como Time=103). Resposta à pergunta: Sim, outliers em V1-V28, Amount podem ser removidos (se <1%), transformados (winsorizing) ou investigados (análise de impacto em Class=0).

Pergunta 5

Conclusão Geral

Resposta

Análise Geral dos Dados de Transações

Esta análise sintetiza as conclusões sobre o dataset de transações financeiras, com 284 registros, focando em tipos de dados, padrões temporais, outliers e recomendações.

Tipos de Dados

Colunas numéricas (contínuas): Time, V1 a V28, Amount. Coluna categórica (discreta): Class (todos valores 0, sem fraudes).

Padrões e Tendências Temporais

O Time aumenta monotonicamente até 265s, com Amount exibindo variabilidade (média ~80, mediana ~12.99). Tendência de aumento no volume e variância, sem fraudes detectadas.

Valores Atípicos (Outliers)

Outliers identificados via IQR em V1-V28 (~7.7%) e Amount (8.8%, ex: 3828.04). Nenhum em Time ou Class.

Exemplo de Outliers em Amount (Formatação Condicional)

Time	Amount	Status
103	3828.04	Outlier Alto
50	10	Normal
200	7712.43	Outlier Alto

Remoção, Transformação ou Investigação

Time: Remover se não essencial. V1-V28: Investigar e transformar (z-score). Amount: Log-transformar e investigar outliers. Class: Manter.

Conclusões Gerais

Os dados representam transações normais (sem fraudes), com tendências temporais de aumento na variabilidade de Amount. Outliers em features PCA e Amount sugerem necessidade de investigação para ruído ou anomalias potenciais. Recomenda-se transformações para normalização e remoção de Time irrelevante, preparando o dataset para modelagem preditiva. Insights principais: Atividade financeira estável, mas com picos que demandam atenção; ausência de fraudes reforça foco em detecção futura.

Conclusão

Documento consolidado com objetivos, prompts, métodos, perguntas, instalação, tecnologias e memória, incluindo gráficos/diagramas ilustrativos.