

INTRODUÇÃO Descrição do Projeto Público Alvo Justificativa para escolha do tema

HISTÓRIA DO USUÁRIO

Componentes de Suporte

INTEGRANTES DO GRUPO

Tecnologias Principais

DIAGRAMA 3 ARQUITETURA DA SOLUÇÃO 3 PROPOSTA PRELIMINAR DO 4 DESENVOLVIMENTO DO PROJETO Arquitetura do Sistema 4

1

2

5

LINHA DO TEMPO	9
CRONOGRAMA	7
Desafios Identificados e Soluções	7
Métricas de Sucesso	6
Metodologia de Desenvolvimento	5

1. Descrição do Projeto

O tema escolhido é a extração de dados de documentos fiscais, como notas fiscais eletrônicas, com o objetivo de tornar esse processo mais fácil, rápido e preciso. A ideia é criar uma solução que ajude profissionais e empresas de contabilidade, finanças e tecnologia a coletar, organizar e usar informações importantes de forma automática.

Com essa solução, queremos:

- Recuperar documentos fiscais em fontes conhecidas e confiáveis, tais como a Receita Federal ou prefeituras, seja por upload manual ou download.
- Por meio das tecnologias OCR (reconhecimento óptico de caracteres), inteligência artificial, incluindo modelos de linguagem (LLM), "ler" os documentos e extrair informações como valores, datas, nomes e códigos fiscais.
- Possibilitar que o sistema aprenda com o tempo, adaptando-se a diferentes layouts e formatos de notas fiscais, com o objetivo de impedir que alguma informação não seja coletada. Armazenar essas informações de forma estruturada para que possam ser consultadas ou analisadas a qualquer momento.
- Oferecer uma interface simples onde os usuários possam fazer perguntas e receber respostas claras sobre os dados fiscais.

O foco é economizar tempo, reduzir erros humanos e ajudar empresas, especialmente as que lidam com muitos documentos por dia, como no setor varejista, a cumprir suas obrigações fiscais e realizar auditorias com mais eficiência.

2. Público Alvo

Profissionais e empresas da área de contabilidade, finanças e tecnologia, especialmente aqueles envolvidos com automação de processos fiscais, compliance tributário e extração de dados de documentos fiscais (como notas fiscais eletrônicas).

3. Justificativa para escolha do tema

Empresas que lidam com grandes volumes de notas fiscais precisam extrair dados com rapidez e precisão para cumprir obrigações fiscais e realizar auditorias internas. A adoção de tecnologias como OCR e NLP permite automatizar essa extração, reduzindo erros humanos e custos operacionais. Por exemplo, uma empresa do setor varejista que processa milhares de notas por dia pode economizar centenas de horas de trabalho ao adotar essa solução.

4. História do Usuário

Como profissional da área de contabilidade, finanças ou tecnologia, eu quero uma solução capaz de capturar e extrair automaticamente os dados de documentos fiscais (NF-e), para que eu possa obter essas informações de forma rápida, precisa e organizada, reduzindo erros manuais e otimizando meus processos operacionais.

Critérios de Aceitação:

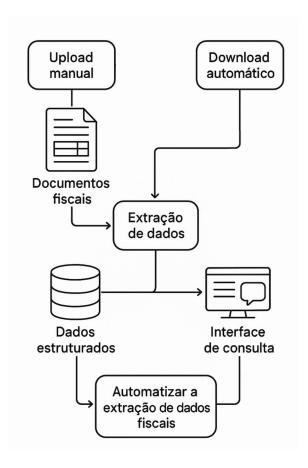
- 1. O sistema deve permitir o upload manual de documentos fiscais em formato PDF ou imagem.
- 2. O sistema deve ser capaz de receber uploads ou realizar o download automático de documentos fiscais a partir de fontes oficiais (SEFAZ).
- 3. A solução deve aplicar tecnologias de OCR e inteligência artificial para extrair dados dos documentos, independentemente de variações no layout.
- 4. As informações extraídas devem ser armazenadas de forma estruturada e acessível.
- Deve existir uma interface de interação onde o usuário possa realizar consultas e obter respostas sobre os dados fiscais, como valores, impostos, datas e outros campos relevantes.
- 6. O sistema deve garantir precisão na extração dos dados, minimizando falhas de reconhecimento ou perdas de informação.

Objetivo do Negócio:

Automatizar o processo de extração de dados fiscais, visando:

- Otimização de tempo operacional;
- Redução de erros manuais;
- Maior controle e segurança das informações fiscais;
- Suporte eficiente à tomada de decisão e auditorias.

5. Diagrama



6. Arquitetura da solução



A solução implementa um pipeline automatizado para processamento de documentos fiscais.

 Agente 1 (Aquisição de Documentos): Responsável por obter documentos fiscais (NFe) em formatos de imagem e PDF, provenientes de upload manual ou download de órgãos governamentais.

- 2. **Agente 2 (Extração e Aprendizado):** Processa os documentos adquiridos, utilizando OCR para extrair dados e aprender novos layouts com apoio de LLM e dos arquivos armazenados obtidos pelo agente 1, garantindo a extração precisa de informações fiscais relevantes.
- 3. Base de Conhecimento: Utiliza os dados estruturados extraídos pelo Agente 2.
- 4. **Agente 3 (Resposta e Interação):** Acessa um Large Language Model (LLM) e, utilizando os dados da Base de Conhecimento, responde às perguntas dos usuários sobre as informações fiscais.
- 5. **Usuário:** Interage com o sistema através de uma interface, recebendo as respostas do Agente 3.

Essa arquitetura permite a automação completa do ciclo de vida dos documentos fiscais, desde a coleta até a disponibilização inteligente das informações.

7. Proposta preliminar do desenvolvimento do projeto

7.1 Arquitetura do Sistema

O sistema será desenvolvido seguindo uma arquitetura multi-agente composta por três agentes especializados:

Agente 1: Aquisição de Documentos

Responsabilidade: Obter e pré-processar documentos fiscais Funcionalidades:

- Interface para upload manual de arquivos (PDF, imagens)
- Integração com APIs de órgãos governamentais (SEFAZ)
- Validação inicial de formato e integridade dos documentos
- Organização e catalogação dos arquivos recebidos

Agente 2: Extração e Aprendizado

Responsabilidade: Processar documentos e extrair dados relevantes Funcionalidades:

- OCR avançado para digitalização de documentos
- NLP para identificação e extração de campos específicos
- IA para adaptação a novos layouts
- Validação cruzada de dados extraídos

Agente 3: Resposta e Interação

Responsabilidade: Interface inteligente com usuários Funcionalidades:

• Integração com LLMs para consultas em linguagem natural

7.2 Componentes de Suporte

Fontes de Documentos

Upload manual via interface web

Integração com sistemas governamentais

Armazenamento e Acesso a LLMs

Banco de dados SQLite para documentos processados Cache inteligente para otimização de performance Integração com APIs de LLMs (Gemini)

Base de Conhecimento

Metadados extraídos organizados por categorias Logs de processamento para auditoria Histórico de aprendizado dos algoritmos Templates de documentos fiscais brasileiros

7.3 Tecnologias Principais

Backend e Processamento

Python como linguagem principal Urllib3 para consumir APIs Langchain como biblioteca de interação com as LLMs SQLite para documentos e metadados

Inteligência Artificial

Tesseract OCR + OpenCV para reconhecimento de texto GeminiAl para capacidades avançadas de LLM

Frontend e Interface

React.js

Tailwind CSS para estilização responsiva Lucide React para ícones (Send, Bot, User, Loader2, etc.) Fetch API para chamadas HTTP ao LangChain

Infraestrutura

GitHub para versionamento e divulgação do código

7.4 Metodologia de Desenvolvimento

Fase 1: Levantamento de Requisitos – Primeira Apresentação

- Análise detalhada de tipos de documentos fiscais brasileiros
- Definição de campos obrigatórios para extração
- Estudo de regulamentações fiscais aplicáveis
- Coleta de amostras de documentos para treinamento (Agente 2)

Fase 2: Desenvolvimento OCR + NLP - Agente 2 - Primeira Apresentação

- Implementação do motor de OCR otimizado
- Desenvolvimento de algoritmos de NLP para extração de campos
- Criação de templates para diferentes tipos de documentos e aprendizado

Fase 3: Testes Iniciais – Primeira Apresentação

- Validação com conjunto de documentos de teste
- Ajustes de precisão e correção de bugs
- Documentação técnica inicial

Fase 4: Atividades Finais – Primeira Apresentação

- Demonstração do MVP funcional
- Apresentação de métricas de precisão alcançadas
- Planejamento de melhorias

Fase 5: Interface - Agente 1 + Frontend - Segunda Apresentação

- Desenvolvimento de APIs para download de arquivos
- Criação da interface web de usuário
- Implementação de funcionalidades avançadas
- Testes de download de dados com sites reais

Fase 6: Atividades Finais – Segunda Apresentação

- Demonstração do sistema completo
- Apresentação de casos de uso reais
- Análise de ROI e benefícios mensuráveis
- Roadmap para desenvolvimento futuro

Fase 7: Validação e Ajustes – Terceira Apresentação

- Testes com usuários finais
- Correções e otimizações finais
- Preparação da documentação completa
- Validação de compliance

Fase 8: Apresentação final Intermediária - Terceira Apresentação

- Apresentação final do projeto
- Entrega de código-fonte e documentação
- Demonstração de impacto e resultados
- Plano de continuidade e manutenção

Fase 9: Apresentação Final (Parte 1)

• Entrega de código-fonte e documentação

Fase 10: Apresentação Final (Parte 2)

• Entrega de código-fonte e documentação

7.5 Métricas de Sucesso

Técnicas

Precisão de extração: > 95% para campos obrigatórios Tempo de processamento: < 30 segundos por documento

Taxa de falsos positivos: < 3%

Disponibilidade do sistema: > 99.5%

Negócio

Redução de tempo de processamento: > 80% Economia de custos operacionais: > R\$ 50.000/ano

Satisfação do usuário: > 4.5/5.0

ROI do projeto: > 300% no primeiro ano

7.6 Desafios Identificados e Soluções

Desafio 1: Variedade de Layouts

Problema: Documentos fiscais possuem layouts diversos Solução: Machine Learning adaptativo e templates dinâmicos

Desafio 2: Qualidade de Imagens

Problema: Documentos escaneados com baixa qualidade

Solução: Pré-processamento avançado de imagens e OCR robusto

Desafio 3: Compliance Legal

Problema: Adequação às normas fiscais brasileiras

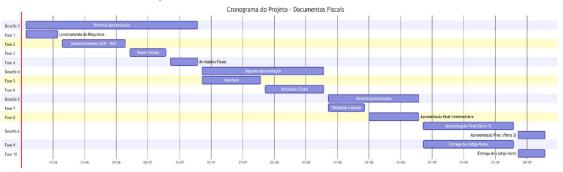
Solução: Consultoria especializada e validação jurídica contínua

8. Cronograma

Fase	Atividades Principais	Período Estimado	Duração
	Desafio 3 – Primeira Apresentação	09/06 à 17/07	
Fase 1	Levantamento de Requisitos - Análise detalhada de tipos de documentos fiscais brasileiros - Definição de campos obrigatórios para extração - Estudo de regulamentações fiscais aplicáveis - Coleta de amostras de documentos para treinamento	09/06 à 16/06	8 dias
Fase 2	Desenvolvimento OCR + NLP - Agente 2 - Implementação do motor de OCR otimizado - Desenvolvimento de algoritmos de NLP para extração de campos - Criação de templates para diferentes tipos de documentos e aprendizado.	17/06 à 01/07	15 dias
Fase 3	Testes Iniciais - Elaboração de plano de testes - Validação com conjunto de documentos de teste - Ajustes de precisão e correção de bugs - Documentação técnica inicial	02/07 à 10/07	9 dias
Fase 4	Atividades Finais - Planejamento de melhorias - Apresentação de métricas de precisão alcançadas - Demonstração do MVP funcional	11/07 à 17/07	7 dias

	Desafio 4 – Segunda Apresentação	18/07 à 14/08	
Fase 5	Interface - Agente 1 + Frontend - Desenvolvimento de APIs para download de arquivos - Criação de interface web - Implementação de funcionalidades avançadas - Testes de download de dados com sites reais	18/07 à 31/07	14 dias
Fase 6	Atividades Finais - Demonstração do sistema completo - Casos reais e ROI - Roadmap futuro	01/08 à 14/08	14 dias
	Desafio 5 – Terceira Apresentação	15/08 à 04/09	
Fase 7	Validação e Ajuste - Testes com usuários finais - Correções e otimizações finais - Preparação da documentação completa - Validação de compliance	15/08 à 23/08	9 dias
Fase 8	Apresentação final intermediária - Entrega de código-fonte e documentação - Demonstração de impacto e resultados - Plano de continuidade e manutenção	24/08 à 04/09	12 dias
	Desafio 6 – Apresentação Final (Parte 1)	05/09 à 25/09	
Fase 9	- Entrega de código-fonte e documentação	05/09 à 25/09	21 dias
	Desafio 6 – Apresentação Final (Parte 2)	26/09 à 02/10	
Fase 10	- Entrega de código-fonte e documentação	26/09 à 02/10	7 dias

9. Linha do Tempo



10. Integrantes do Grupo

- Ana Paola Zarate Zequita
- Antonio João Nascimento Dantas
- Aurélio Marques Morbeck
- Daniel Correa Rodrigues
- Eduarda Silveira Cardoso
- Lorrane da F C Santos Santana
- Luciane Schumacher
- Matheus de Oliveira Vieira
- Valdinei de Souza Camargo
- Walison Carlos da Silva